

Report

Instructor: Zheng Wu

Name: 赵旭令 (AI 院系), StudentId: 231300088

1 任务概述

本实验要求在课程提供的 BrowseComp-Plus 本地语料和 BM25 检索器基础上，实现一个能够进行多轮检索、维护中间状态、压缩上下文并基于证据输出最终答案的 Deep Research Agent。实验约束包括：不替换课程提供的检索器，不使用 Google/Bing 等外部检索服务，不引入额外外部知识库；模型侧通过本地 vLLM OpenAI-compatible 接口调用。

当前实现主要围绕以下目标展开：

1. 实现多轮检索 loop，并设置明确停止条件。
2. 将问题分解、检索执行、答案综合、答案验证拆成相对独立的子模块。
3. 在有限上下文窗口内维护检索历史、证据文档、验证记录和待验证子目标。
4. 对不同 agent 配置进行消融实验，并分析错误来源。
5. 实现 OpenTrack 的多轨迹候选融合与答案审查，并保证不使用测试集答案或评测结果构造训练数据。

2 方法设计

2.1 整体架构

本项目实现的主 agent 位于 `agent/deep_research_agent.py`。整体结构由四个阶段组成：

1. **Planner**：将原始复杂问题拆解为子问题、关键词、初始搜索 query 和需要验证的约束。
2. **Search Executor**：执行初始检索和 ReAct 过程中的工具调用，并记录工具轨迹。
3. **Evidence Store**：维护已执行搜索、已召回文档、打开文档内容、关键词窗口、验证记录和去重信息。
4. **Answer Synthesizer / Verifier**：根据压缩证据综合最终答案，并用验证器检查候选答案是否被证据支持。

图 1 给出了基础 DeepResearch agent 与 OpenTrack 融合模块的流程。

运行入口为 `agent/run_deep_research.py`。该脚本批量读取数据集，调用 agent，并输出符合提交格式的 JSONL 轨迹文件。




图 1: DeepResearch agent 与 OpenTrack 候选融合流程

2.2 工具设计

在课程原始搜索工具基础上，当前实现使用以下本地工具：

1. `decompose_question`: 确定性问题拆解 fallback，用于生成初始搜索 query。
2. `search`: 调用本地 BrowseComp-Plus BM25 索引，返回 docid、分数、URL 和摘要。
3. `get_document`: 根据 docid 打开较长文档片段；如果提供 keyword，则返回关键词附近窗口。
4. `verify_claim`: 对候选答案或中间声明进行本地词面验证，辅助发现明显 unsupported 的候选。

所有工具均使用本地语料和本地索引，不访问外部互联网。

2.3 状态管理与停止条件

为了避免模型在多轮检索中反复搜索同一 query 或重复验证同一 claim，EvidenceStore 维护了如下状态：

1. 已执行 query 集合，用于跳过重复搜索。
2. 已召回文档集合，用于统计新信息量。
3. 文档详情和关键词窗口，用于构造压缩证据上下文。

4. 验证历史和 ReAct 验证计数，用于限制重复验证。

主要停止条件包括最大 ReAct 轮数、最大总工具调用数、连续无新文档轮数和模型直接给出最终答案。当前常用默认参数为：最大 ReAct 轮数 6，初始 query 数 7，每次检索 top-8，总工具调用预算 36。

2.4 答案综合与验证

答案综合 prompt 明确要求先判断题目需要的 answer type，再输出短答案，避免输出解释、引用、角色名或中间线索。验证阶段调用 LLM verifier，要求只有证据直接支持 exact answer 时才给出 supported。后续实验发现，词面验证和 LLM verifier 仍可能把错误槽位答案判为 supported，因此额外实现了可选的 `--answer-audit` 消融，用于在最终写出前再次检查 answer type 和约束链。

2.5 OpenTrack 候选融合

除单次 agent run 外，本项目还实现了 `agent/fuse_deep_research_runs.py`。该脚本读取多个合法 agent 轨迹，抽取候选答案和证据片段，再调用本地模型作为 judge 进行重判。融合策略以一个稳定 base run 为默认答案；只有当 judge 给出足够高置信度、候选分数优势和证据支持时，才允许覆盖 base answer。该设计用于避免多轨迹融合把当前已知正确答案改错。

最终 OpenTrack 版本采用 relaxed fusion：保留 base run 保护，但允许 judge 在置信度达到 80、候选分数至少高 4 分且满足证据支持时覆盖 base answer。该设置使一个原先错误的日期题被改为正确答案，同时没有丢失 baseline 已答对的题。

需要强调的是，融合脚本只读取题目、已有 submission 轨迹、工具输出和模型自身产生的候选，不读取 eval 文件中的标准答案或评测标签。评测结果只用于实验报告中的事后分析。

3 实验设置

3.1 模型与服务

主要实验使用 Qwen3-8B，通过 vLLM 启动 OpenAI-compatible 服务：

```
vllm serve ./Qwen3-8B \
  --served-model-name qwen_auto \
  --enable-auto-tool-choice \
  --tool-call-parser hermes \
  --trust-remote-code \
  --host 0.0.0.0 \
  --port 8000
```

agent 侧通过 `http://127.0.0.1:8000/v1` 访问模型服务。默认关闭 Qwen thinking 输出，以提高工具调用格式稳定性。

3.2 数据与评估

当前已完成实验主要在 `browsecomp_plus_hard50.jsonl` 上进行诊断。评估使用课程提供的 `agent/eval.py`，由本地模型判断预测答案与标准答案是否语义等价。

需要说明的是，hard50 在本项目中仅作为调试和诊断集合使用。不会用其标准答案、评测结果或 query-level 正误标签构造训练数据、硬编码规则或选择最终答案。

4 实验结果

表 1 总结了已完成的主要 run。基础任务 baseline 采用 v6/v8 稳定多轮 DeepResearch 配置，准确率为 14%。OpenTrack 最终版本采用 relaxed candidate fusion，准确率为 16%。

实验版本	主要配置	正确数	准确率	备注
early baseline	初始多轮 agent	3/50	6%	工具调用多，但答案槽位错误严重
v5 stable	稳定检索配置	6/50	12%	回到较稳定主线
v6 docref	docid 引用修正与证据压缩	7/50	14%	当前单 run 最优之一
v7 broader	更宽检索预算	6/50	12%	召回更多但噪声上升
v8 repeatcap	限制重复 verify	7/50	14%	与 v6 持平，减少重复验证
v9 avoid clues	避免复制题干线索	6/50	12%	作为默认策略过强，已关闭
fused v1	非保守候选融合	6/50	12%	judge 覆盖过激，改错已有正确题
fused v2 conservative	保守融合，base=v6	7/50	14%	不退步，但未新增正确题
v10 answer-audit	最终 answer-type 审查	6/50	12%	直接作为最终 run 会退步
LoRA preliminary	小规模 LoRA 尝试	2/50	4%	训练数据不足，暂不采用
fused v3 audit candidates	加入 audit 候选的保守融合	7/50	14%	接受 2 次覆盖，但未新增正确题
v11 wide overnight	激进宽召回与答案 ensemble	4/50	8%	证据噪声过多，全部达到工具预算上限
v14 balanced overnight	降低预算后的长运行配置	4/50	8%	仍被额外证据干扰，未采用
fused v5 balanced	保守融合，加入 v14 候选	7/50	14%	保留 baseline 正确题，但未新增
fused v6 relaxed	relaxed 覆盖阈值	8/50	16%	最终 OpenTrack 版本，新增 query 159
fused v7 all runs	全候选池 relaxed fusion	7/50	14%	候选过多导致 judge 退回错误 base 候选

表 1: 主要实验结果

5 错误分析

5.1 总体观察

从多次分析结果看，错误主要分为两类：

1. **召回不足**：标准答案对应证据未出现在工具输出中，说明 query reformulation 和文档定位仍不足。
2. **召回后抽错**：标准答案或关键证据已经出现在工具输出中，但最终答案抽成了中间实体、相关人物、相邻作品、年份或反向关系。

第二类错误尤其重要，因为它表明当前瓶颈不只是 BM25 召回，而是多跳约束绑定和 answer type 对齐不足。v6/v8 分析中均出现若干道“gold appeared in tool output but final answer was wrong”的样例。这类题说明模型已经接触到相关证据，但综合阶段没有严格回到题干询问的槽位。

5.2 错误轨迹案例

以下选取基础 v6 轨迹中的 10 个错误案例进行归因。之所以主要分析 v6，是因为 v6 是基础任务达标版本，并且保留了完整工具调用轨迹；最终 fused 版本本身不重新调用检索工具，因此其错误更多体现为候选选择问题。

1. **442，复杂书目链条召回不足**。预测为“The Founding of the Colony”，标准答案为“THE DAWN OF AUSTRALIAN COLONISATION”。轨迹中执行了 9 次 search 和 8 次 verify，但标准答案未出现在工具输出中，预测答案却出现在证据里。归因是 query 主要命中了第二本书的相邻主题，没有定位到“first chapter title”这个最终槽位。
2. **549，人物线索被错误实体吸引**。预测为 Belle da Costa Greene，标准答案为 Marguerite Smith。轨迹中标准答案未召回，但预测实体被检索到且 verifier 给出 supported。归因是模型抓住了“librarian”

这个强线索后跳到更著名的图书馆员，没有把 “Dakotas writer / long-term partner / Europe visit / death in late 1950s” 绑定到同一人。

3. **241, 答案粒度不够。**预测为 “Queen of Romania”, 标准答案为 “Queen Marie of Romania”。标准答案相关文本已经出现在工具输出中，但最终只输出了头衔而不是完整人名。归因是 answer synthesizer 满足了类型 “historical figure” 的粗粒度要求，却没有遵守 “name” 的精确输出要求。
4. **930, 年份槽位混淆。**预测为 1776, 标准答案为 2001。标准答案已在工具输出中出现，但最终答案选成了被分析文本或历史背景中的年份。归因是题目询问 research paper 的提交/发表相关年份，模型把中间作品线索的年代当成最终答案。
5. **747, 国家关系方向错误。**预测为 Canada, 标准答案为 Japan。标准答案已被召回，且 v6 verifier 对错误答案给过 supported。归因是问题中包含出生地、产业产量、人物经历等多个国家线索，模型选择了路径上的中间国家，没有沿着 “Person A worked for an aide to Person B” 的关系继续推到目标国家。
6. **662, 同类名词邻近干扰。**预测为 apples, 标准答案为 pears。标准答案已出现在工具输出中，但模型选择了同一段证据里的另一个水果名。归因是局部词面验证只看到水果和诗人线索重叠，缺少对 “father tried to grow what” 这一具体谓词的约束。
7. **869, 时间条件和年级槽位混淆。**预测为 5th, 标准答案为 kindergarten。标准答案已被召回，但模型输出了同一人物教育经历中的另一个年级。归因是题目包含 “as of December 31, 2013”、年龄、伴侣、职业等多重时间条件，模型没有把指定时间点对应到正确年级。
8. **487, 多跳亲属关系反向。**预测为 Nick Cassavetes, 标准答案为 Edward Norton。标准答案已出现在工具输出中，v6 verifier 也曾支持错误候选。归因是题目问 actor，但线索链包含 “town construction director”、“father of spouse”、“actor’s ...” 等反向亲属关系，模型把导演/相关人物当成目标 actor。
9. **159, 错误日期被 OpenTrack 修正。**v6 预测为 06-06-2025, 标准答案为 October 15, 2016。基础轨迹把网页检索日期或无关日期当成最后演出日期；relaxed fusion 比较多个轨迹候选后选择 October 15, 2016，使该题从错误变为正确。归因是单轨迹答案综合阶段未区分 “页面日期” 和 “play last performance date”，而多轨迹候选融合提供了纠错机会。
10. **761, 数值抽取失败导致拒答。**预测为 None, 标准答案为 7%。轨迹中执行了 10 次 search 和 8 次 verify，但没有可靠定位到 annual report 中 EPS 增幅的具体百分比。归因是财报类问题需要精确数值和表格/段落定位，BM25 摘要容易召回公司报告周边文本，却不一定保留目标数字。

5.3 消融结论

1. **扩大检索预算不一定有效。**v7 broader 召回文档数上升，但准确率从 14% 降到 12%，说明更多证据会增加干扰。
2. **重复 verify 限制是稳定改进。**v8 与 v6 持平，同时减少无效重复验证，有利于控制工具预算。
3. **过强的 clue-copy guard 会退步。**v9 试图避免复制题干值，但会误伤一些本来需要重复实体或短答案的题。
4. **非保守融合有风险。**fused v1 将已有正确答案覆盖为错误答案，说明 judge 必须以强基线保护为前提。

5. **answer-audit 不能直接作为最终输出。** v10 的审查能提出一些有价值候选，但也会错误覆盖答案；因此更适合把 audit 结果作为融合候选，而不是直接替换最终答案。
6. **audit 候选融合仍未突破当前上限。** fused v3 将 answer-audit 产生的候选答案加入融合，最终仍为 14%。本次融合接受了两个覆盖，但覆盖前后均未命中正确答案，说明仅靠已有轨迹候选重排暂时无法产生新的正确题。
7. **宽召回不是主要方向。** v11 和 v14 都明显退步，说明在 Qwen3-8B 上，把更多文档塞进上下文会让答案综合更容易选到相邻实体。
8. **relaxed fusion 是目前最有效的 OpenTrack 改进。** fused v6 将 query 159 从错误日期改为正确日期，最终达到 16%，但进一步加入全部历史 run 的 fused v7 又回落到 14%，说明融合候选池也需要控制噪声。

6 OpenTrack 与训练说明

当前已实现 OpenTrack 相关代码：

1. open_track/run.py: 复现 OpenTrack 最终 relaxed fusion。
2. agent/fuse_deep_research_runs.py: 多轨迹候选融合和证据 judge。
3. open_track/build_sft_data.py: 将合法成功轨迹转换为 SFT 数据。
4. open_track/merge_sft_data.py: 合并多个合法开发集 run 的 SFT 数据。
5. open_track/train.py: 基于本地模型路径进行 LoRA 或全量微调。
6. open_track/merge_lora.py: 将 LoRA adapter 合并回 base model，便于 vLLM 服务部署。

为了避免数据泄漏，当前版本已经强制要求构造 SFT 数据时声明 `--source-split train` 或 `--source-split dev`。如果声明 `--source-split test`，脚本会直接拒绝运行。后续如果进行训练，只能使用合法 train/dev 轨迹，不能使用 hard50 或最终测试集的答案、评测标签和按题筛选结果。

本次最终提交不采用微调模型。原因是初步 LoRA 实验只有 4% 准确率，低于未训练 agent；同时课程答疑明确禁止使用评估 50 题成功轨迹或 BrowseComp-Plus 830 条剩余评估数据构造 SFT 数据。因此最终 OpenTrack 分数来自无泄漏的 agent 架构和多轨迹融合，而不是训练集答案记忆。

7 复现命令

7.1 主线 agent

```
python -m agent.run_deep_research \
  --dataset browsecomp_plus_hard50.jsonl \
  --index-path indexes/browsecomp_plus_bm25.sqlite \
  --model qwen_auto \
  --base-url http://127.0.0.1:8000/v1 \
  --output runs/deep_research_submission.jsonl
```

7.2 评估

```
python -m agent.eval \  
  --submission runs/deep_research_submission.jsonl \  
  --dataset browsecomp_plus_hard50.jsonl \  
  --model qwen_auto \  
  --base-url http://127.0.0.1:8000/v1 \  
  --output runs/deep_research_eval.jsonl
```

7.3 OpenTrack 最终融合

```
python -m agent.fuse_deep_research_runs \  
  --dataset browsecomp_plus_hard50.jsonl \  
  --submission v6=runs/deep_research_submission_v6_docref.jsonl \  
  --submission v8=runs/deep_research_submission_v8_repeatcap.jsonl \  
  --submission old_v11=runs/deep_research_submission_v11_overnight.jsonl \  
  --submission old_v12=runs/deep_research_submission_v12_overnight_no_react_verify.jsonl \  
  --submission old_v13=runs/deep_research_submission_v13_overnight_heuristic.jsonl \  
  --submission v14=runs/deep_research_submission_v14_balanced_overnight.jsonl \  
  --base-label v6 \  
  --override-confidence 80 \  
  --override-score-margin 4 \  
  --protected-base-extra-confidence 0 \  
  --protected-base-extra-margin 0 \  
  --model qwen_auto \  
  --base-url http://127.0.0.1:8000/v1 \  
  --output runs/deep_research_submission_fused_v6_relaxed.jsonl
```

8 当前结论

目前实现已经完成了课程要求中的多轮检索、停止条件、历史与上下文管理、prompt 设计和基于证据的最终回答；同时实现了候选融合、答案审查和 OpenTrack 训练脚本。基础 DeepResearch baseline 达到 14%，OpenTrack relaxed fusion 最终达到 16%。主要瓶颈仍是复杂多跳问题中的证据召回不足和答案槽位抽取错误；实验表明，盲目扩大检索预算会降低准确率，受控候选融合比继续增加上下文更有效。